Day 32 機器學習

機器學習-流程與步驟

知識地圖 機器學習 - 模型選擇 機器學習-流程與步驟

機器學習概論 Introduction of Machine Learning

監督式學習
Supervised Learning

前處理 Processing → 探索式數據分析 Exploratory Data Analysis → 特徵工程 Feature Engineering → **模型選擇 Model selection** → 參數調整 Fine-tuning → 集成 Ensemble

非監督式學習
Unsupervised Learning

- 分群 Clustering
- 降維 Dimension Reduction

模型選擇 Model selection

概論

- 驗證基礎
- 預測類型
- 評估指標

基礎模型 Basic Model

- 線性回歸 Linear Regression
- 邏輯斯回歸 Logistic Regression
- 套索算法 LASSO
- 嶺回歸 Ridge Regression

樹狀模型 Tree based Model

- 決策樹 Decision Tree
- 隨機森林 Logistic Regression
- 梯度提升機 Gradient Boosting Machine

本日知識點目標

- 了解一個完整機器學習專案的細節
- 機器學習專案的開發流程步驟
- 每個步驟的意義及該如何進行

機器學習專案開發流程

01 資料搜集、前處理

02 定義目標與評估準則

03 建立模型與調整參數

04 導入

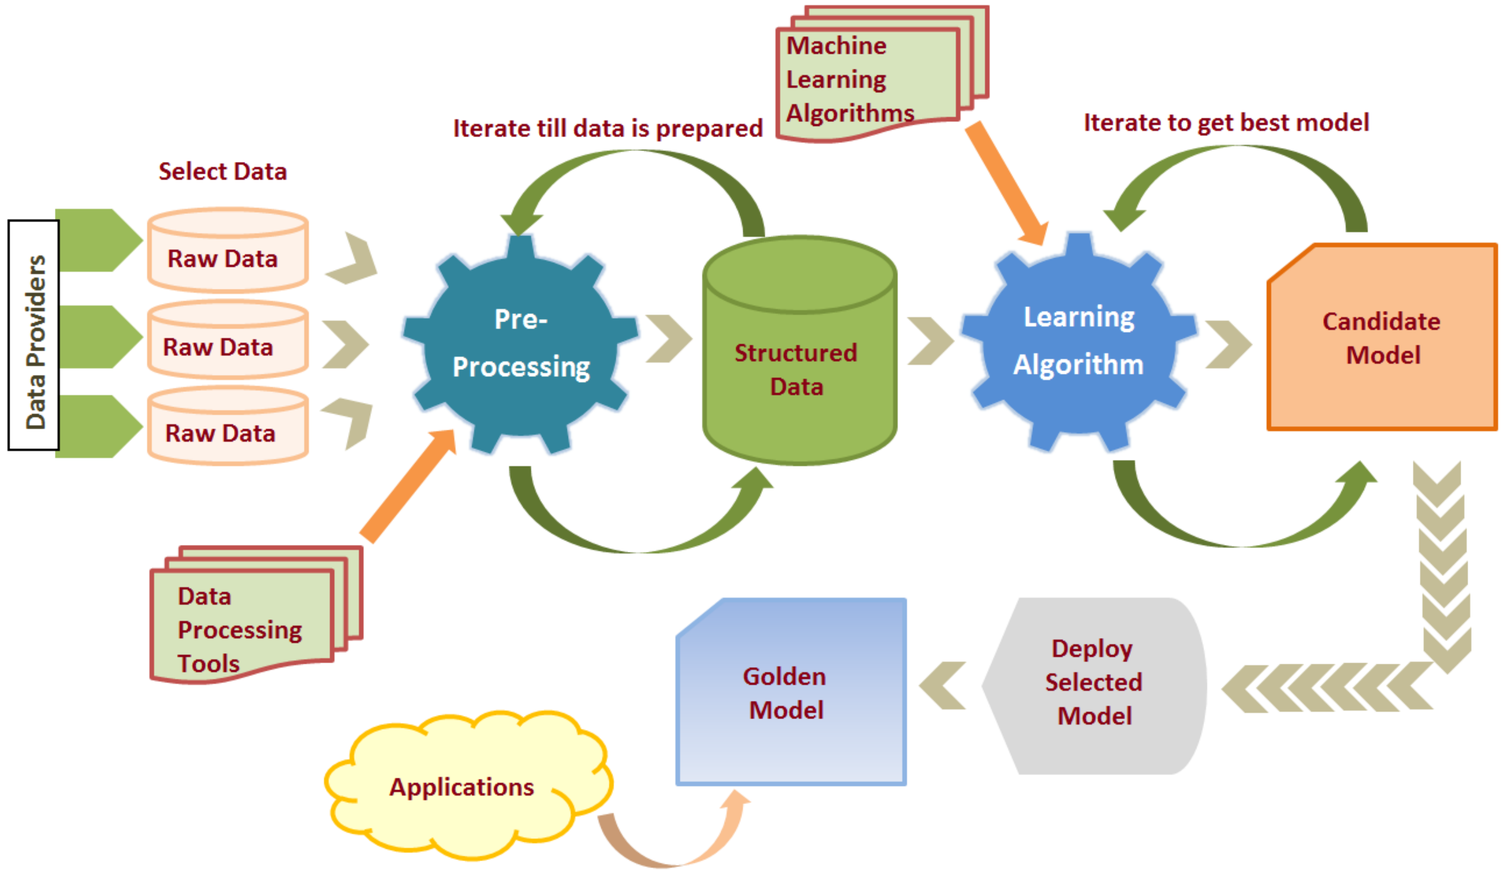

圖片來源：IMARTICUS

1.1 資料在哪? 結構為何?

- 政府公開資料集、Kaggle 資料集
- 結構化資料
  - Excel 檔 (.xlsx)
  - CSV 檔 (.csv, 逗號分隔)

- 非結構化資料
  - 圖片
  - 影音
  - 文字

1.2 如何開啟、處理檔案?

- Python!
- 多數檔案都能使用 Python 的套件開啟
  - 開啟圖片: PIL, skimage, open-cv…
  - 開啟文件: pandas
- 資料前處理
  - 缺失值填補
  - 離群值處理
  - 標準化

2. 定義目標

- 回歸問題? 分類問題?
- 要預測的目標是甚麼? (target 或 y)
- 要用甚麼資料來進行預測? (predictor 或 x)
- 將資料分為
  - 訓練集, training set
  - 驗證集, validation set
  - 測試集, test set

2. 設定評估準則

- 不同問題有不同的評估指標
- 回歸問題 (預測值為實數)
  - RMSE, Root Mean Square Error
  - Mean Absolute Error
  - R-Square
- 分類問題 (預測值為類別)
  - Accuracy
  - F1-score
  - AUC, Area Under Curve

3. 建立模型並調整參數

- 根據設定目標建立機器學習模型
  - Regression, 回歸模型
  - Tree-based model, 樹模型
  - Neural network, 神經網路
- 各模型都有其超參數需調整，根據經驗與對模型了解、訓練情形等進行調參

4. 導入

- 建立資料搜集、前處理等流程
- 送進模型進行預測
- 輸出預測結果
- 視專案需求整合前後端
  - 建議統一資料格式，方便讀寫 (.json, .csv)

常見問題

Q: 如何確立一個機器學習模型的可用性？

A: 當我們訓練好一個機器學習模型，為了驗證其可行性，多半會讓模型正式上線，觀察其在實際資料進來時的結果；有時也會讓模型跟專家進行 PK，挑一些真實資料讓模型與專家分別測試，評估其準確率。

解題時間
It’s Your Turn

請跳出PDF至官網Sample Code＆作業
開始解題